Reinforcement Learning

TANIGUCHI Taichi

September 14, 2019

Contents

I Abstract **2**

II UCL Course on RL **2**

1 Introduction **2**

2 Introduction on RL(第一回) **3**
2.1 強化学習の概要 3
2.2 エージェントの構成 6
2.2.1 Policy(方策) 6
2.2.2 Value FUnction(価値関数) 6
2.2.3 Model 7
2.2.4 エージェントのカテゴリー 7
2.3 意思決定の問題点 7
2.3.1 Reinforcement Learning 7
2.3.2 Planning 8
2.4 まとめ 8

3 Markov Decision Processes(第二回目) **8**
3.1 Markov Processes(マルコフ過程) 8
3.2 Markov Reward Process(マルコフ報酬過程) 9
3.3 Markov Decision Process(マルコフ決定過程) 11

III 強化学習 **12**

4 Introduction **12**

5 マルコフ決定過程 (MDP) **12**

6 価値関数 **13**
6.1 状態価値関数・行動価値関数 13

7 方策改善定理 **14**
7.1 グリーディー方策 14
7.2 コンサバティブ方策 15

8 ベルマン方程式 (Bellman Equation) **15**
8.1 ベルマン作用素 16

9 予測問題と制御問題 **16**
9.1 予測問題 16

IV 逆強化学習 **17**

Part I
Abstract

ここでは、強化学習の基礎の理解を目的とする。強化学習は囲碁のプロを倒した AI、アルファ碁を 100 戦 100 勝するという偉業を成し遂げたアルファ・ゼロに用いられているアルゴリズムであり、自動運転の開発もこの強化学習をもとに行われている。

Part II
UCL Course on RL

1 Introduction

この章では [1] で得られた知識をまとめる。[1] では機械学習の分野の一つである、強化学習の入門が説明されている。UCL(ユニヴァーシティ・カレッジ・ロンドン) というイギリスの有名大学の講義であり、講師は David Silver という方である。彼はコンピューターサイエンスの博士であり、DeepMind で働いている。

2 Introduction on RL(第一回)

第一回は [2] で Youtube を通して視聴できる。[3] には日本人の方がこの講義の第一回をまとめれておられる。今回は英語の講義なので聞き取ることができなかったところなど、わからないところをカバーする意味で参考にさせていただいた。

2.1 強化学習の概要

はじめは強化学習の実装例がいくつか紹介されていた。ヘリコプターで複雑な運転を競う曲芸操縦や、Backgammon というすごろくを二人で行うゲームや、ポートフォリオの運営、ロボットの歩行などが紹介されていた。

強化学習は Reward Hypothesis というものを前提にしている。

定義 (Reward Hypothesis)**.** 全ての目的は、累積された報酬によって記述することができる

四つのポイントがあげられている。

- 目的: 将来の報酬を最大化するような行動をとる
- 行動は長期的な結果を持つかもしれない
- 目前の報酬は犠牲にした方が、長期的には報酬を最大化させることがあるかもしれない

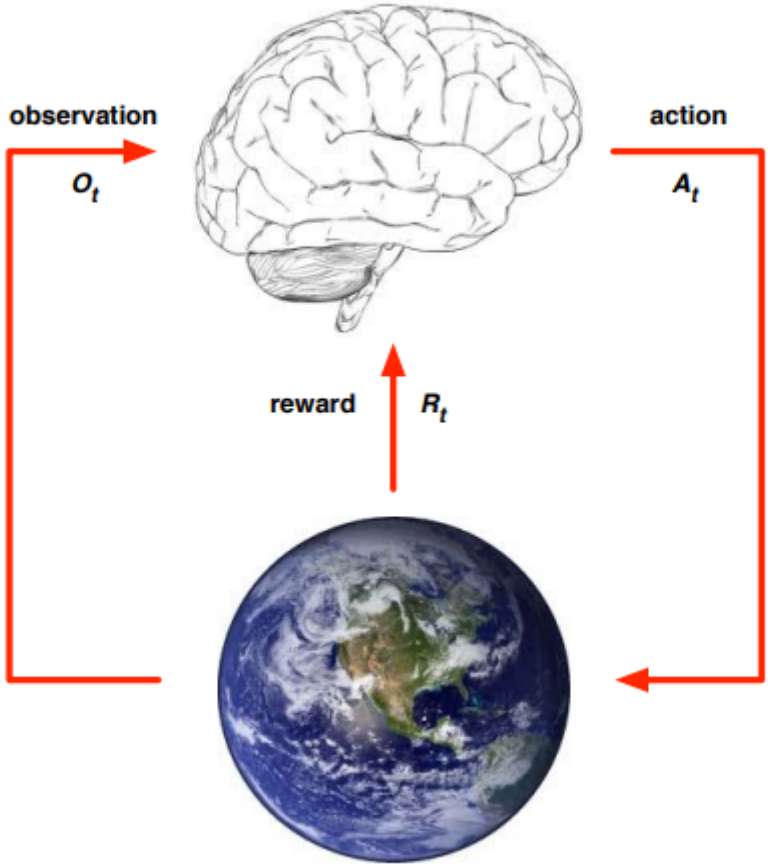

この画像のうち、脳は Agent（エージェント）、地球は Environment（環境）を表している。各ステップ t でエージェントは

- 行動 A_t を実行
- 状況 O_t を受け取る
- 報酬 R_t を受け取る

環境は

- 行動 A_t を受け取る

- 状況 O_{t+1} を放出する
- 報酬 R_{t+1} を放出する

定義 (history). 状況、行動、報酬の列を history とする。

$$H_t = O_1, R_1, A_1, ..., A_{t-1}, O_t, R_t$$

次のエージェントの行動と環境が選択する状況や報酬はこの history に依存する。

State（状況) は次に何が起こるかを決定するために使われる情報を持っている。フォーマルには、状況は history の関数になっている。

$$S_t = f(H_t)$$

Environment stateS_t^e は環境の性質だけを表す。普通はエージェントには見えない。見えたとしても、それは無関係な情報を持っている。
一方、エージェント状況 S_t^a はエージェントの内部を表している。例えば、次の行動をとるために使うエージェントの情報などである。これは強化学習のアルゴリズムに使われる。これは history の関数であるので、$S_t^a = f(H_t)$ を表せる。
情報状況は history からのすべての情報を含んでいるマルコフ状況である。マルコフ性とは

定義 (Markov(マルコフ性)). S_t がマルコフ性であるとは

$$\mathbb{P}(S_{t+1}|S_t) = \mathbb{P}(S_{t+1}|S_1, S_2, .., S_t)$$

となることである。つまり、将来の状況は過去の状態に依存せず、現在の状態のみに依存するということである。

定義 (Full observability(完全な観測可能性)). エージェントが直接、環境状況を観測できることをいう。

$$O_t = S_t^a = S_t^e$$

が成り立つ。

この状態の時、フォーマルには、マルコフ決定過程である。マルコフ決定過程については、次の lecture で詳しく解説される。

定義 (Oartial observability(部分的観測可能性)). エージェントが関節的に環境状況を確認することができる。この時、エージェント状況と環境状況は一致しない。

この状態の時は、フォーマルには Partially observable markov decision process(部分的マルコフ決定過程) である。

2.2 エージェントの構成

以下の三つがある。ただし、必須ではない。

- Policy(方策): エージェントの行動関数
- Value function: どのような状況や行動がよいのかの判断をする関数
- Model: エージェントから見た環境の表現

一つずつ解説されている。

2.2.1 Policy(方策)

方策はエージェントの行動である。これは状況から行動への写像とみることができる。

定義 (Deterministic policy(決定論的方策))**.**

$$a = \pi(s)$$

エージェントの行動は状態 s に基づいて決定される。現在の状態で最終的に報酬を最大化することができる行動をとることができる。

定義 (Stochastic policy(確率的方策))**.**

$$\pi(a|s) = \mathbb{P}(A_t = a|S_t = s)$$

エージェントの行動は一定の確率に従って決定される。ランダムに行動を選択しなければいけない場合に用いる。

2.2.2 Value FUnction(価値関数)

価値関数は将来の報酬を予測する関数である。ある状態においてそれがよいことなのか、悪いことなのかを評価するために使われる。

$$v_\pi(s) = \mathbb{E}_\pi[R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + ...|S_t = s]$$

[3] ではこのようにまとめられている。

> ある状態やあるアクションによって、将来どのくらい報酬が得られるかの予測値を表す (より多くの報酬を得られると予測できる状態はより良い状態)。State Value Function(状態価値関数) と Action Value Function(行動価値関数) の 2 つという分け方や、Optimal Value Function(全ての方策において最適化された価値関数) がある。

2.2.3 Model

モデルは環境が次にすることを予測します。

定義 (Transition Model).

$$P_{ss}^{a} = \mathbb{P}(S_{t+1} = s | S_t = s, A = a)$$

次の状態が現在の状態と行動に依存しているモデル。

定義 (Reward Moel).

$$R_{s}^{a} = \mathbb{E}[R | S = s, A = a]$$

現在の状態と行動から所得できる報酬 R の期待値をとるモデル。

2.2.4 エージェントのカテゴリー

以下の三つがある。

- Value Based:Value function のみ使う
- Policy Based:policy のみ使う
- Actor Critic:policy, value function を使う

また、

- Model Free: モデル無し
- Model Based: モデルあり

と分類されている。

2.3 意思決定の問題点

意思決定の問題点には二つの種類がある。

2.3.1 Reinforcement Learning

- 環境は最初は不明
- エージェントは環境とやり取りする
- エージェントは方策を向上させる

2.3.2 Planning

- 環境のモデルは不明
- エージェントはそのモデルのみを使って計算する
- エージェントは方策を向上させる

2.4 まとめ

講義ではヘリコプターやゲームなどたくさんの具体例を使ってた。マルコフ性を仮定した話が多かった。強化学習を勉強する上でたくさん定義があり、カテゴライズされているので勉強する範囲が広そうだと感じた。

英語が早すぎてついていけないのはどうしようか。。。（笑）講義では、講師が積極的に学生に質問を求めていてなんて学生に気を配った授業なんだとびっくりした。

3 Markov Decision Processes(第二回目)

第二回は [4] で視聴できる。[5] によると、Markov Decision Processes[MDPs](マルコフ決定過程) とは

> 状態遷移が確率的に生じる動的システム（確率システム）の確率モデルであり、状態遷移がマルコフ性を満たすものをいう。

と書いてある。
マルコフ決定過程は強化学習のための環境を記述するこ t ができる。そして、ほとんどの強化学習の問題はマルコフ決定過程で形式化される。

- Optimal control primarily は連続的な MDPs を処理する
- 部分的観測問題は MDPs に変換できる
- Bandits は一つの状態において、MDPs

3.1 Markov Processes(マルコフ過程)

定義 (確率過程)**.** 確率過程とは時間によって変動する確率変数のことである。

定義 (Markov(マルコフ性))**.** 確率過程 S_t がマルコフ性であるとは

$$\mathbb{P}(S_{t+1}|S_t) = \mathbb{P}(S_{t+1}|S_1, S_2, ..., S_t)$$

を満たすときにゆう。

つまり、現在の状態が S_t であるとき、将来で状態 S_{t+1} になる確率は現在の状態 S_t にのみ依存し、過去の一切の情報は関係ないこと示している。

定義 (state transition probability(状態遷移確率))**.** 確率過程 S の状態遷移確率 P_{ss} とは

$$P_{ss} = \mathbb{P}(S_{t+1} = s | S_t = s)$$

である。

また、状態遷移行列 P とは (s, s) 成分に P_{ss} を持つ行列のことである。これはそれぞれの列を足し合わせると 1 が縦に並ぶベクトルになる。

マルコフ過程は無記憶な確率過程である。

定義 (Markov Process(マルコフ過程))**.** S を無限集合、P を状態遷移行列とする。この時、(S,P) をマルコフ過程という。

3.2 Markov Reward Process(マルコフ報酬過程)

定義 (Markov Rewar Process(マルコフ報酬過程))**.** S を状態を要素に持つ無限集合、P を確率過程 S の状態遷移行列、$R_s = \mathbb{E}[R_{t+1}|S_t = s]$ を報酬関数、$\gamma \in [0, 1]$ を割引率とすると、マルコフ報酬過程とは (S, P, R, γ) のことである。

定義 (toral discounted reward(合計割引率報酬))**.** 時刻 t において、将来の報酬の合計 G_t は

$$G_t = R_{t+1} + \gamma R_{t+2} + ... = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1}$$

である。

$\gamma \in [0, 1]$ は現在における将来の価値を表す。$k + 1$ 回のステップが終わった後、受け取る報酬 R は $\gamma^k R$ である。
が 0 に使い程、近い将来の報酬を重要視し、γ が 1 に近いほど、遠い将来の報酬を優先している。

なぜ、割り引くのか??

- 数学的に扱いやすくするため
- マルコフ過程での無限大を避けるため
- 将来における不確実性が完全に表されていないかもしれない
- もし報酬が金融であるとき、即座な報酬は長期における報酬より多くの利益を得ることがある。

- 人間や動物は即座の報酬を優先することがある。

これらが理由として挙げられる。

定義 (Value Function(価値関数)). 価値関数とは $v(s)$

$$v(s) = \mathbb{E}[G_t|S_t = s]$$

価値関数は即座に得る報酬とそのあとの状態が割り引かれた値に分けることができる。

$$\begin{aligned}
v(s) &= \mathbb{E}[G_t|S_t = s] \\
&= \mathbb{E}[R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + ...|S_t = s] \\
&= \mathbb{E}[R_{t+1} + \gamma(R_{t+2} + \gamma R_{t+3} + ...)|S_t = s] \\
&= \mathbb{E}[R_{t+1} + \gamma G_{t+1}|S_t = s] \\
&= \mathbb{E}[R_{t+1} + \gamma v(S_{t+1})|S_t = s] \\
&= E[R_{t+1}|S_t = s] + \gamma \mathbb{E}[v(S_{t+1})|S_t = s] \\
&= R_s + \gamma \sum_{s \in S} P_{ss} v(s)
\end{aligned}$$

ここで次の方程式を定義する

定義 (Bellman Equation).

$$v = R + \gamma P v$$

これを Bellman 方程式という。ここで v は状態毎に変わる列ベクトルである。

$$\begin{pmatrix} v(1) \\ \vdots \\ v(n) \end{pmatrix} = \begin{pmatrix} R_1 \\ \vdots \\ R_n \end{pmatrix} + \gamma \begin{pmatrix} P_{11} & \dots P_{1n} \\ \vdots & \\ P_{11} & \dots P_{nn} \end{pmatrix} \begin{pmatrix} v(1) \\ \vdots \\ v(n) \end{pmatrix}$$

と書ける。

Bellman 方程式は線形方程式であるので、解析的に解を求めることが可能である。

$$\begin{aligned}
v &= R + \gamma P v \\
(1 - \gamma P) v &= R \\
v &= (1 - \gamma P)^{-1} R
\end{aligned}$$

巨大な MRPs を反復的に解く方法たくさんある。

- Dynamic programing

- Monte-Carlo evalution
- Temporal-Difference learning

が代表的である。

3.3 Markov Decision Process(マルコフ決定過程)

定義 (Markov Decision Process(マルコフ決定過程)).
- S は状態を要素に持つ無限集合
- A は行動を要素に持つ無限集合
- P は状態遷移行列
- $P_{ss}^{a} = \mathbb{P}(S_{t+1} = s | S_t = s, A_t = a)$
- R は報酬関数、$R_s^a = \mathbb{E}[R_{t+1} | S_t = s, A_t = a]$
- $\gamma \in [0.1]$ は割引率

この時、(S, A, P, R, γ) をマルコフ決定過程という。

定義 (Policy(方策)). 方策 π とは、状態 s が与えられた時の条件付き確率分布

$$\pi(a|s) = \mathbb{P}[A_t = a | S_t = s]$$

として定義される。

次のことがゆえる。

$$A_t \ \sim \pi(|S_t), \quad \forall t > 0$$

マルコフ決定過程 (S, A, P, R, γ) と方策 π は与えられる。状態の数列 $S_1, S_2, ...$ はマルコフ過程 $(S, P^{\pi}$ です。
状態と報酬の数列 $S_1, R_1, S_2, ...$ はマルコフ報酬過程 $(S, P^{\pi}, R^{\pi}, \gamma$ である。ここで

$$P_{s,s}^{\pi} = \sum_{a \in A} \pi(a|s) P_{s,s}^{a}$$

$$R_s^{\pi} = \sum_{a \in A} \pi(a|s) R_s^a$$

である。

定義 (状態価値関数). マルコフ決定過程の状態 s から開始した状態価値関数は

$$v_{\pi}(s) = \mathbb{E}_{\pi}[G_t | S_t = s]$$

定義 (行動価値関数). 行動価値関数は

References

[1] http://www0.cs.ucl.ac.uk/staff/d.silver/web/Teaching.html

[2] https://www.youtube.com/watch?v=2pWv7GOvuf0t=6s

[3] https://qiita.com/YN6127yn/items/23662e7607c947208c2f

[4] https://www.youtube.com/watch?v=lfHX2hHRMVQ

[5] https://ja.wikipedia.org/wiki/マルコフ決定過程

[6] $https://qiita.com/short-clawed_otter/items/e006dd4892e4e28cdef6$

Part III
強化学習

4 Introduction

強化学習の目的は、割引報酬の総和の期待値を最大にさせる行動を推定することにある。

5 マルコフ決定過程 (MDP)

マルコフ決定過程とは、強化学習において環境を表すことができる。マルコフ決定過程は次のように構成される。

定義 (確率過程). 確率過程とは時間によって変動する確率変数のことである。

定義 (Markov(マルコフ性)). 確率過程 S_t がマルコフ性であるとは

$$\mathbb{P}(S_{t+1}|S_t) = \mathbb{P}(S_{t+1}|S_1, S_2, ..., S_t)$$

を満たすときにゆう。

つまり、現在の状態が S_t であるとき、将来で状態 S_{t+1} になる確率は現在の状態 S_t にのみ依存し、過去の一切の情報は関係ないこと示している。

定義 (state transition probability(状態遷移確率)). 確率過程 S の状態遷移確率 P_{ss} とは

$$P_{ss} = \mathbb{P}(S_{t+1} = s|S_t = s)$$

である。

定義 (Markov Process(マルコフ過程))**.** S を無限集合、P を状態遷移行列とする。この時、(S,P) をマルコフ過程という。

定義 (マルコフ決定過程)**.**

$$(S, A, p, r, \gamma)$$

ただし、S は状態空間、A は行動空間、$p : S \times A \to M(S)$ は遷移確率、$r : S \times A \times S \to \mathbb{R}$ は報酬関数、$\gamma \in [0, 1)$ は割引率である。

これらは、

- エージェントが状態 s にいる。
- 行動 a をとった
- 確率 $P(s|s, a)$ で状態 s に遷移する。
- 報酬 $r(s, a, s)$ を受け取る。

6 価値関数

6.1 状態価値関数・行動価値関数

価値関数には、「状態価値関数」、「行動価値関数」の二つがある。状態価値関数は、エージェントの目的に対してのある状態の価値を表す。行動価値関数は、エージェントの目的に対してのある行動の価値を表す。

式では、どのようになるかを確認する。まずは、状態価値関数である。エージェントは方策 $\pi(a|s)$ という確率分布に従って行動する。したがって、

$$v^{\pi}(s) = \mathbb{E}_{\pi}[\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t, s_{t+1}) | s_0 = s]$$

となる。つまり、s から行動を開始して方策 π という確率分布に従う行動（確率変数）をとったときの期待値である。ただし、時間がたつことに γ という割引率がかけられ価値は減っていく。

[1] では次のように書かれており、理解しやすい。

> エージェントの目的は、次のような関数を任意の状態に対して最大とする方策を見つけ出す

次に行動価値関数である。
式は、

$$q^{\pi}(s, a) = \mathbb{E}^{\pi}[\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t, s_{t+1}) | s_0 = s, a_0 = a]$$

となる。これは、ある状態 s から行動 a を行い、方策 π という確率分布に従う行動 (確率変数) をとった時の期待値である。

これらは以下の式で結ばれる。

$$q^{\pi}(s,a) = \frac{E_{\pi}[\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t, s_{t+1}, s_0 = s, a_0 = a]}{P(s_0 = s, a_0 = a)}$$

である。
また、

$$v^{\pi}(s) = \frac{E_{\pi}[\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t, s_{t+1}, s_0 = s]}{P(s_0 = s)}$$

である。
$a_0 = a$ の行動をとる確率は方策 π より $\pi(a|s)$ で与えられる。よって、行動 a で周辺かすることにより、

$$v^{\pi}(s) = \sum_{a} \pi(a|s) q^{\pi}(s,a)$$

が得られる。

[1] によると [2] では、

> 状態遷移が過去の履歴に依存しないなら、現在の状態に依存した方策の集団に最適方策が含まれる事が証明される。

ということが書かれている。つまり、マルコフ性は妥当な仮定であることがわかる。

7 方策改善定理

方策改善定理とは、方策の良しあしを決めるものである。

$$v^{\pi}(s) \geq v^{\pi}(s) \quad \forall s \in S$$

が満たされるとき、π は π よりも良いとされる。

では、どのように良い方策を求めるのか。それには、次の二つの方法がある。

7.1 グリーディー方策

まずは、グリーディー方策について確認する。ある方策 π があるとき、

$$\pi(a|s) = 1 \iff a = \arg\max_{b} q^{\pi}(s,b)$$

を満たす π を π のグリーディー方策という。

このグリーディー方策が π よりよい方策であるとは、この後の section のベルマン方程式を先に確認しなければならない。

$$v^{\pi}(s) = \sum_{a_0} \pi(a_0|s_0 = s) q^{\pi}(s, a_0) \leq \sum_{a_0} \pi(a_0|s_0 = s) q^{\pi}(s, a_0)$$

ここで、

$$q^{\pi}(s, a_0) = \sum_{s_1} p(s_1|s_0 = s, a_0 = a_0)[r(s, a_0, s_2) + \gamma v^{\pi}(s_1)]$$

なので、

$$v^{\pi}(s) \sum_{a_0} \sum_{s_1} p(s_1|s_0 = s, a_0 = a_0) \pi(a_0|s_0 = s)[r(s, a_0, s_1) + \gamma \sum_{a_1} \pi(a_1|s_1) q^{\pi}(s_1, a_1)]$$

これを繰り返せば、

$$v^{\pi}(s) \leq \mathbb{E}^{\pi}[\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t, s_{t+1})|s_0 = s] = v^{\pi}$$

が得られる。つまり、π は π よりもいい方策となる。

[r(s,a0,s1)+ a1 (a1|s1)q (s1,a1)]

7.2 コンサバティブ方策

8 ベルマン方程式 (Bellman Equation)

では、どのようにして価値関数を学習すればよいのか。最も簡単な方法は、モンテカルロ法である。これは、

$$\sum_{t=0}^{\infty} \gamma^t r(s_t, a_t, s_{t+1})$$

を何度も繰り返してサンプルし、平均を計算する方法である。しかし、これは一般的に分散が大きく収束が遅いといわれている。

実際の応用では、行動価値関数を学習し、方策の改善を行う。行動の価値関数の学習では、ベルマン方程式を用いる。ベルマン方程式とは、

$$q^{\pi}(s, a) = r(s, a) + \gamma \sum_{s} p(s|s, a) v^{\pi}(s)$$

である。ただし、

$$r(s, a) = \sum_{s} p(s|s, a) r(s, a, s)$$

状態価値関数は、行動価値関数と同じように学習する。

$$\boldsymbol{q}^{\pi} = (q(s_1, a_1), .., q(s_{N_s}, a_1), q(s_1, a_2), ..., q(s_{N_s}, a_{N_A}))^T$$

とする。各行動に対する各状態の行動価値関数の列である。[1] では次のように書かれている。

価値関数をヒルベルト空間の要素と考える。

行列 $\boldsymbol{P}^\pi$ を

$$\boldsymbol{P}^\pi \boldsymbol{q}^\pi = (\sum_s p(s|s_1, a_1)v^\pi(s), ..., \sum_s p(s|s_{N_s}, a_{N_A})v^\pi(s))^T$$

となるような行列とする。この $\boldsymbol{P}^\pi$ を用いると、

$$\boldsymbol{q}^\pi = \boldsymbol{r} + \gamma \boldsymbol{P}^\pi \boldsymbol{q}^\pi$$

となる。ただし、$\boldsymbol{r}$ は $r(s,a)$ を要素とする $\boldsymbol{q}^\pi$ と同じような順番で並べたベクトルである。

8.1 ベルマン作用素

次のような作用素を定義する。

$$\boldsymbol{T}^\pi(\boldsymbol{X}) = \boldsymbol{r} + \gamma \boldsymbol{P}^\pi X$$

これはベルマン作用素と呼ばれる。

次にベルマン最適作用素を定義する。

$$\forall \boldsymbol{q} \qquad (\boldsymbol{T}\boldsymbol{q})(s,a) = r(s,a) + \gamma \sum_s p(s|s,a) \max_a q(s,a)$$

よって、$\boldsymbol{q}$ に対する greedy 方策を π とすると、

$$\boldsymbol{T}\boldsymbol{q} = \boldsymbol{T}^\pi \boldsymbol{q} = r(s,a) + \gamma \sum_s p(s|s,a) q(s, \arg\max_a q(s,a))$$

となる。

9 予測問題と制御問題

9.1 予測問題

方策を固定し、

References

[1] $https://qiita.com/short-clawed_otter/items/e006dd4892e4e28cdef6$

[2] $https://zodml.org/sites/default/files/Markov_Decision_Processes_and_Artificial_Intelligence.pdf$

Part IV
逆強化学習

逆強化学習とは、普通の強化学習が報酬関数を最大化させるような最適な行動を求めるのに対して、最適な行動をもとに最適な報酬関数を求めるときに使う。報酬関数をどのような形にするのかは以外と簡単ではない。そこで、最適な行動がわかっているときは逆強化学習によって、報酬関数を決定することがある。

References

[1] https://qiita.com/neka-nat@github/items/aaab6184aea7d285b103